


Reducción de dimensionalidad

ANÁLISIS DE COMPONENTES PRINCIPALES

Mg Sc. Meza Rodríguez, Aldo Richard

armeza@ulima.edu.pe



El análisis componentes principales

El análisis de componentes principales es una técnica multivariada que permite encontrar nuevas variables que en menor número simplifican la información contenida en las variables originales

Objetivos

- ❖ Identificar patrones ocultos en un conjunto de datos.
- ❖ Reducir la dimensionalidad de los datos eliminando el ruido y la redundancia de los mismos.
- ❖ Identificar variables correlacionadas.
- ❖ Sirve como paso previo para otras técnicas

Características y requisitos



Características y requisitos



Cálculo de los autovalores y autovectores

Para el cálculo de los autovalores λ_j y autovectores v_j muestrales se utiliza el Teorema de Descomposición Espectral. Siendo A la matriz de variancias-covariancia muestral que estima a Σ , entonces expresando en términos de los estimadores se tiene:

$$\underbrace{(A - \lambda I)}_{n \times n} \cdot v = 0_v$$

donde $\hat{\lambda}_j$ y v_j son los estimadores del autovalor λ_j y autovector v_j asociado respectivamente.

Análisis de Componentes Principales

$$\begin{aligned} Y_1 &= W_{11}X_1 + W_{12}X_2 + \dots + W_{1p}X_p \\ Y_2 &= W_{21}X_1 + W_{22}X_2 + \dots + W_{2p}X_p \\ &\vdots \\ Y_p &= W_{p1}X_1 + W_{p2}X_2 + \dots + W_{pp}X_p \end{aligned}$$

$$\begin{bmatrix} Y_1 \\ \vdots \\ Y_p \end{bmatrix} = \begin{bmatrix} W_{11} & \dots & W_{1p} \\ \vdots & \ddots & \vdots \\ W_{p1} & \dots & W_{pp} \end{bmatrix} \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix}$$

$$\text{siendo } \begin{cases} \text{Var}(y_1) = \lambda_1 \\ \text{Var}(y_2) = \lambda_2 \\ \vdots \\ \text{Var}(y_p) = \lambda_p \end{cases}$$

Para que Y_1 capte la mayor variabilidad de los datos sus coeficientes deben ser las coordenadas del autovector u_1 de la matriz de covarianzas Σ de las variables originales que corresponden al mayor autovalor λ_1 . De igual modo, para que el segundo componente principal sea no correlacionado con el primero y capte la variabilidad que no ha sido explicada por éste, sus coeficientes deben ser las coordenadas del autovector u_2 de la matriz Σ cuyo autovalor λ_2 es el que le sigue en valor al primer autovalor λ_1 , y así sucesivamente hasta obtener p componentes principales. Se considera que cada autovector u_i debe ser unitario, es decir, de longitud 1.

Algoritmo del ACP

1. Calcular la matriz de covariancia global Σ_X
2. Calcular los autovalores de Σ_X , $\lambda_1, \lambda_2, \dots, \lambda_p$
3. Calcular los autovectores v_1, v_2, \dots, v_p asociados a $\lambda_1, \lambda_2, \dots, \lambda_p$
4. Formar la matriz $W = [v_1, v_2, \dots, v_p]$

Propiedades

$$Var(Y_i) = \lambda_i$$

$$V(Y_1) \geq V(Y_2) \geq \dots V(Y_p)$$

$$\sum_{i=1}^p Var(X_i) = \lambda_1 + \lambda_2 + \dots + \lambda_p = \sum_{i=1}^p Var(Y_i)$$

$$\sum_{i=1}^p Var(Y_i) = \lambda_1 + \lambda_2 + \dots + \lambda_p = \sum_{i=1}^p Var(Z_i) = p$$

$$\frac{\lambda_k}{\lambda_1 + \dots + \lambda_p}, k=1, \dots, p \quad \frac{\lambda_k}{p}, k=1, \dots, p$$

1



•La varianza de la i-ésima componente principal es igual a su autovalor asociado.

2



•Las varianzas están en orden decrecientes

3



•La suma de las varianzas de los componentes es igual a la de las variables originales


4



La proporción explicada por la por las k primeras componentes respecto a la variabilidad total es:

Número de componentes a retener

❖ Criterio del grafico de sedimentación (Scree Plot)



❖ Criterio de la media aritmética

Se debe seleccionar aquellas componentes cuyo autovalor excede de la media de los autovalores.