


# Probabilidad y Regresión Logística

Clasificación

# Visión Probabilística de la Regresión

- $y = w_1x + w_0$
- Hay infinitos modelos
- Elegir el modelo con la mayor probabilidad



# MLE (Maximum Likelihood Estimation)

- Estimación de máxima verosimilitud
- Problema de optimización.
- Permite estimar densidades de probabilidad de un conjunto de datos

# Probabilidad

$$P(x; w) = L(x; w)$$

$$\max L(x; w) = \max \prod_i P(x_i; w)$$

Tomamos el logaritmo porque valores muy pequeños causan problemas. En lugar de 0.0001 se tiene -9.21.....

$$\max \log L(x; w) = \max \sum_i \log P(x_i; w)$$

# Aplicando en regresión

- $y = w_1x + w_0$
- $P(y|x) \rightarrow \max \sum_i \log P(y_i|x_i; h)$
- $h$  es la función que buscamos
- $h$  no necesariamente debe ser regresión lineal

# Equivalencia de MLE y Regresión Lineal

$$\max \sum_i \log P(y_i | x_i; h)$$

$$h \rightarrow y = w_1 x + w_0$$

$$P \rightarrow \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \left( \frac{y - \mu}{\sigma} \right)^2}$$

$y - \mu$  es el error

En la regresión tradicional

$$\min \sum_{i=1}^n (y_i - (w_1 x + w_0))^2$$

$y_i - (w_1 x + w_0)$  es el error

$$\max \sum_i \log \frac{1}{\sigma \sqrt{2\pi}} \times e^{-\frac{1}{2} \left( \frac{y_i - (w_1 x + w_0)}{\sigma} \right)^2}$$

En la regresión tradicional

$$\min \sum_{i=1}^n (y_i - (w_1 x + w_0))^2$$


$$\max \sum_i \log \frac{1}{\sigma \sqrt{2\pi}} + \log e^{-\frac{1}{2} \left( \frac{y_i - (w_1 x + w_0)}{\sigma} \right)^2}$$

$$\max \sum_i -\frac{1}{2} \left( \frac{y_i - (w_1 x + w_0)}{\sigma} \right)^2$$

$$\min \frac{1}{2\sigma^2} \sum_i (y_i - (w_1 x + w_0))^2$$



# Regresión Logística




# Regresión Logística

Variables independientes:  
sin cambios a la regresión  
lineal


Variable dependiente:  
Categorica

# La función




- Binaria (0,1)
- Usa la función logística
- $\sigma(z) = \frac{1}{1+e^{-z}}$
- Forma sigmoide

# La función



- Encaja bien con el objetivo de clasificar
- Interpretable como probabilidad

# La función



- Objetivo de la regresión:  
Ajustar la función para que todos los datos de un conjunto estén cerca al 0, y los del otro conjunto, al 1

# Recordemos

- Queremos clasificar en base a atributos
- $x = \{x_1, x_2 \dots, x_n\}$
- $y = \{0,1\}$
- Agregamos pesos a los atributos
- $X = w_1x_1 + w_2x_2 \dots + w_nx_n$

# Transformando la función

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$


$z$  es la suma ponderada de las variables independientes

$$z = w^T x$$

$$P(\text{clase} = 1) = \frac{1}{1 + e^{-w^T x}}$$

# Limite de Decisión

- $p \geq 0.5, clase = 1$
- $p \leq 0.5, clase = 0$





# Usando MLE para definir la función de pérdida

$$\max \sum_i \log P(y_i | x_i; h)$$

$$h \rightarrow \hat{y} = f(x; w) = \frac{1}{1 + e^{-w^T x}}$$

$$L_i = \hat{y}_i \times y_i + (1 - \hat{y}_i) \times (1 - y_i)$$

Distribución Bernouli

$$P = \begin{cases} p \rightarrow y = 1 \\ 1 - p \rightarrow y = 0 \end{cases}$$



$$\bar{p} = p \times 1 + (1 - p) \times 0$$

# Cross-Entropy

$$\min Costo = CE = -\frac{1}{m} \sum_i y_i \times \log(f(x_i; w)) + (1 - y_i) \times \log(1 - f(x_i; w))$$

En vectores

$$\min -y^T \times \log(f(x; w)) + (1 - y^T) \times \log(1 - f(x; w)) / m$$




# Para encontrar el mínimo

---

- Debemos usar gradient descent
- Puede que hayan varias respuestas (mínimos locales)
- Hay otros algoritmos para leer

## Non-convex Example



La derivada  
de la  
sigmoide

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$


$$\frac{d\sigma}{dz} = \sigma(z)(1 - \sigma(z))$$

Por lo tanto la derivada de la función de costo es...

$$\frac{\partial CE}{\partial w_j} = (f(x_j; w_j) - y)x_j$$

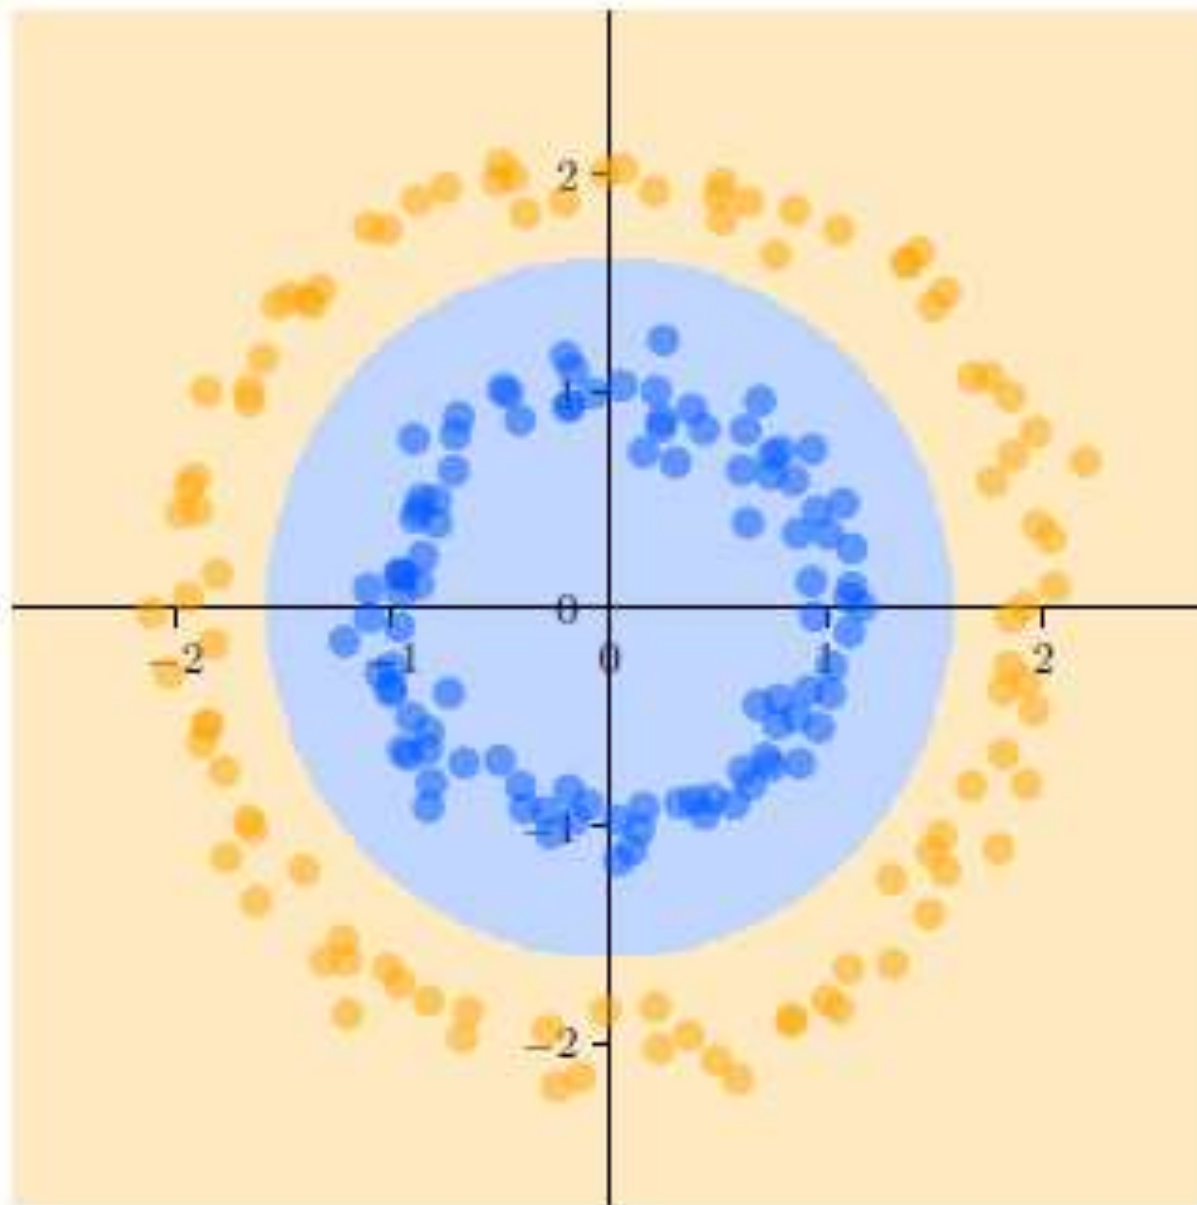
# Para múltiples variables

Uno vs el resto  
(one-vs-rest)




¿Y si no es  
lineal?

---



# Non-linear Decision Boundary


---





# Decision Boundary de grado 2...3...4

- $f = w_0 + w_1x_1 + w_2x_2 + w_3x_1^2 + w_4x_2^2 \dots$
- $W^T \Phi(x)$
- ¿Regularización?



# Regularización

Ridge  $CE + \lambda w^2$

Lasso  $CE + \lambda \|w\|$



# Modelando en Python

```
mirror_mod = modifier_ob.  
# Set mirror object to mirror  
mirror_mod.mirror_object =  
# operation = "MIRROR_X":  
mirror_mod.use_x = True  
mirror_mod.use_y = False  
mirror_mod.use_z = False  
# operation = "MIRROR_Y":  
mirror_mod.use_x = False  
mirror_mod.use_y = True  
mirror_mod.use_z = False  
# operation = "MIRROR_Z":  
mirror_mod.use_x = False  
mirror_mod.use_y = False  
mirror_mod.use_z = True  
  
# selection at the end -add  
mirror_ob.select= 1  
modifier_ob.select=1  
context.scene.objects.active  
("Selected" + str(modifier_ob.name))  
mirror_ob.select = 0  
= bpy.context.selected_objects  
data.objects[one.name].select  
print("please select exactly one object")  
  
--- OPERATOR CLASSES ---  
  
bpy.types.Operator):  
    "X mirror to the selected  
    object.mirror_mirror_x"  
    "Mirror X"  
  
    context):  
        context.active_object is not None
```

# Evaluando nuestro modelo

---

Matriz de Confusión

	Positivo real	Negativo real
Predicción positiva	Verdadero positivo (TP)	Falso positivo (FP) Error tipo I
Predicción negativa	Falso negativo (FN) Error tipo II	Verdadero negativo (TN)

# Evaluando nuestro modelo (Accuracy)

	Positivo real	Negativo real
Predicción positiva	Verdadero positivo (TP)	Falso positivo (FP)
Predicción negativa	Falso negativo (FN)	Verdadero negativo (TN)

- Accuracy (Precision)

- $$\frac{TP+TN}{TP+TN+FP+FN}$$

- Métrica más intuitiva
- No es el más adecuado si la data no está balanceada
- (10 de una clase 0 y 90 de la clase 1)

# Evaluando nuestro modelo (Recall)

	Positivo real	Negativo real
Predicción positiva	Verdadero positivo (TP)	Falso positivo (FP)
Predicción negativa	Falso negativo (FN)	Verdadero negativo (TN)

- Recall (Sensitivity)

- $$\frac{TP}{TP+FN}$$

- Para datos médicos, este valor es importante

# Evaluando nuestro modelo (Specificity )

	Positivo real	Negativo real
Predicción positiva	Verdadero positivo (TP)	Falso positivo (FP)
Predicción negativa	Falso negativo (FN)	Verdadero negativo (TN)

- Specificity

- $$\frac{TN}{TN+FP}$$

# Evaluando nuestro modelo (Precision)

	Positivo real	Negativo real
Predicción positiva	Verdadero positivo (TP)	Falso positivo (FP)
Predicción negativa	Falso negativo (FN)	Verdadero negativo (TN)

- Precision

- $$\frac{TP}{TP+FP}$$



# Evaluando nuestro modelo (F1 Score)

	Positivo real	Negativo real
Predicción positiva	Verdadero positivo (TP)	Falso positivo (FP)
Predicción negativa	Falso negativo (FN)	Verdadero negativo (TN)

- F1 Score
- $F1 = 2 \frac{precision \times recall}{precision + recall}$
- $\frac{TP}{TP + \frac{1}{2}(FP + FN)}$
- Métrica ponderada de Verdaderos positivos
- Útil cuando se le quiere dar más peso a una clase o cuando hay desbalance

# Evaluando nuestro modelo (Resumen)

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) <b>Type II Error</b>	<b>Sensitivity</b> $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) <b>Type I Error</b>	True Negative (TN)	<b>Specificity</b> $\frac{TN}{(TN + FP)}$
		<b>Precision</b> $\frac{TP}{(TP + FP)}$	<b>Negative Predictive Value</b> $\frac{TN}{(TN + FN)}$	<b>Accuracy</b> $\frac{TP + TN}{(TP + TN + FP + FN)}$

Más el F-score

# Resumen de regresión

- Definir la función de pérdida
- Derivar para encontrar la gradiente
- Encontrar el mínimo de la función de pérdida
  - Si se aplica GD y variantes
    - Calcular la gradiente
    - Actualizar pesos
    - Repetir hasta converger en un mínimo
- Evaluar el modelo con data no vista